Найдем FLOPS и BytesMoved для каждого слоя

Convolution $k \times k$

$$FLOPS = 2 \cdot k^2 \cdot C_{in} \cdot C_{out} \cdot H_{out} \cdot W_{out} \cdot B$$

$$BytesMoved = 4(BC_{in}H_{in}W_{in} + C_{out}C_{in}k^2 + BC_{out}H_{out}W_{out})$$

Linear

$$FLOPS = 2BH_{inp}H_{out} \qquad BytesMoved = 4(H_{out}H_{inp} + BH_{inp} + BH_{out})$$

Relu inplace=true

$$FLOPS \simeq 0 \qquad BytesMoved = 4(H_{inp}B + H_{inp}B) = 8H_{inp}B$$

MaxPool

$$FLOPS \simeq 0 \qquad BytesMoved = 4 \cdot BC(H_{inp}W_{inp} + BCH_{out}C_{out}) = 4BC(H_{inp}W_{inp} + H_{out}C_{out})$$

GlobalAvgPool

$$FLOPS = BCHW \qquad BytesMoved \simeq 4BC(HW+1)$$

Тогда для всей модели

$$FLOPS(S;B) \simeq 2 \cdot 7^2 \cdot 3 \cdot 32 \cdot B\left(\frac{S}{2}\right)^2 + 0 + 2 \cdot 5^2 \cdot 32 \cdot 64 \cdot B \cdot \left(\frac{S}{4}\right)^2 + 2 \cdot 3^2 \cdot 64 \cdot 128 \cdot B \cdot \left(\frac{S}{8}\right)^2 +$$
$$+ 2 \cdot 1^2 \cdot 128 \cdot 256 \cdot B \cdot \left(\frac{S}{8}\right)^2 + 2 \cdot 3^2 \cdot 256^2 B \left(\frac{S}{16}\right)^2 + 2 \cdot 1^2 \cdot 256 \cdot 512 B \left(\frac{S}{16}\right)^2 +$$
$$+ B \cdot 512 \cdot \left(\frac{S}{16}\right)^2 + 2B \cdot 512 \cdot 256 + 2B \cdot 256 \cdot 100 = 17714 B S^2 + 313344 B$$

$$BytesMoved = 4\Big(3S^2B + 3 \cdot 32 \cdot 7^2 + B\left(\frac{S}{2}\right)^2 32 + B \cdot 32\left(\left(\frac{S}{2}\right)^2 + \left(\frac{S}{4}\right)^2\right) +$$
$$+ 32 \cdot \left(\frac{S}{4}\right)^2 B + 32 \cdot 64 \cdot 5^2 + 64\left(\frac{S}{4}\right)^2 B + 64 \cdot \left(\frac{S}{4}\right)^2 B + 64 \cdot 128 \cdot 3^2 + 128\left(\frac{S}{8}\right)^2 B +$$
$$+ 128\left(\frac{S}{8}\right)^2 B + 128 \cdot 256 \cdot 1^2 + 256\left(\frac{S}{8}\right)^2 + 256\left(\frac{S}{8}\right)^2 + 256 \cdot 256 \cdot 3^2 +$$
$$+ 256\left(\frac{S}{16}\right)^2 + 256\left(\frac{S}{16}\right)^2 + 256 \cdot 512 \cdot 1^2 + 512\left(\frac{S}{16}\right)^2 + 512B \cdot \left(\frac{S}{16}\right)^2 +$$
$$+ 512B + 512B + 512 \cdot 256 + 256B + 2 \cdot 256B + 256B + 256 \cdot 100 + 100B\Big) =$$
$$= 196S^2B + 8592B + 4.159.872$$

Временную рабочую память примем 0.
Также примем, что одновременно живы вход и выход слоя

$$Mem = Mem_{весов} + \max(Mem_i) + Mem_{image}$$

$$Mem_i = 4 \cdot (Mem_{input_i} + Mem_{out})$$

$Mem_0 = 4 \cdot 115^2 B$
$Mem_1 = 4 \cdot 105^2 B$
$Mem_2 = 4 \cdot 105^2 B$
$Mem_3 = 4 \cdot 65^2 B$
$Mem_4 = 4 \cdot 65^2 B$
$Mem_5 = 4 \cdot 65^2 B$
$Mem_6 = 4 \cdot 55^2 B$
$Mem_7 = 4 \cdot 35^2 B$
$Mem_8 = 4(25^2 B + 512 B)$
$Mem_9 = 4 \cdot 768 B$
$Mem_{relu} = 4256 B$
$Mem_{11} = 4356 B$

Th. $S \geq 32$ то $\max(Mem_i) = 4 \cdot 115^2 B$

$$Mem = 405^2 B + 4.159.872 + 125^2 B = 525^2 B + 4.159.872$$

$$Latency = t_0 + \max(FLOPS(S;B)/\Theta_1; BytesMoved(S;B)/\Theta_2)$$

$$Energy = E_{фоновая} + E_{FLOPS} + E_{BytesMoved} =$$

$$= \Theta_0 Latency + \Theta_1 FLOPs(S;B) + \Theta_2 BytesMoved(S;B)$$